面向边缘场景的大模型高效微调 · Qwen2.5-1.5B · 单卡 RTX 4090

16 种微调方法同条件对比：LoRA 用一半显存超过全参微调

同一基座、同一数据、同一训练预算下，对比 LoRA / QLoRA / DoRA / PiSSA 等 16 种方法与不微调基线，共 34 组训练和 3 组附加评测。结论：**LoRA 在常识推理和数学推理上都略高于全参微调，峰值显存约减半，通用知识遗忘只有全参的约 1/9。**

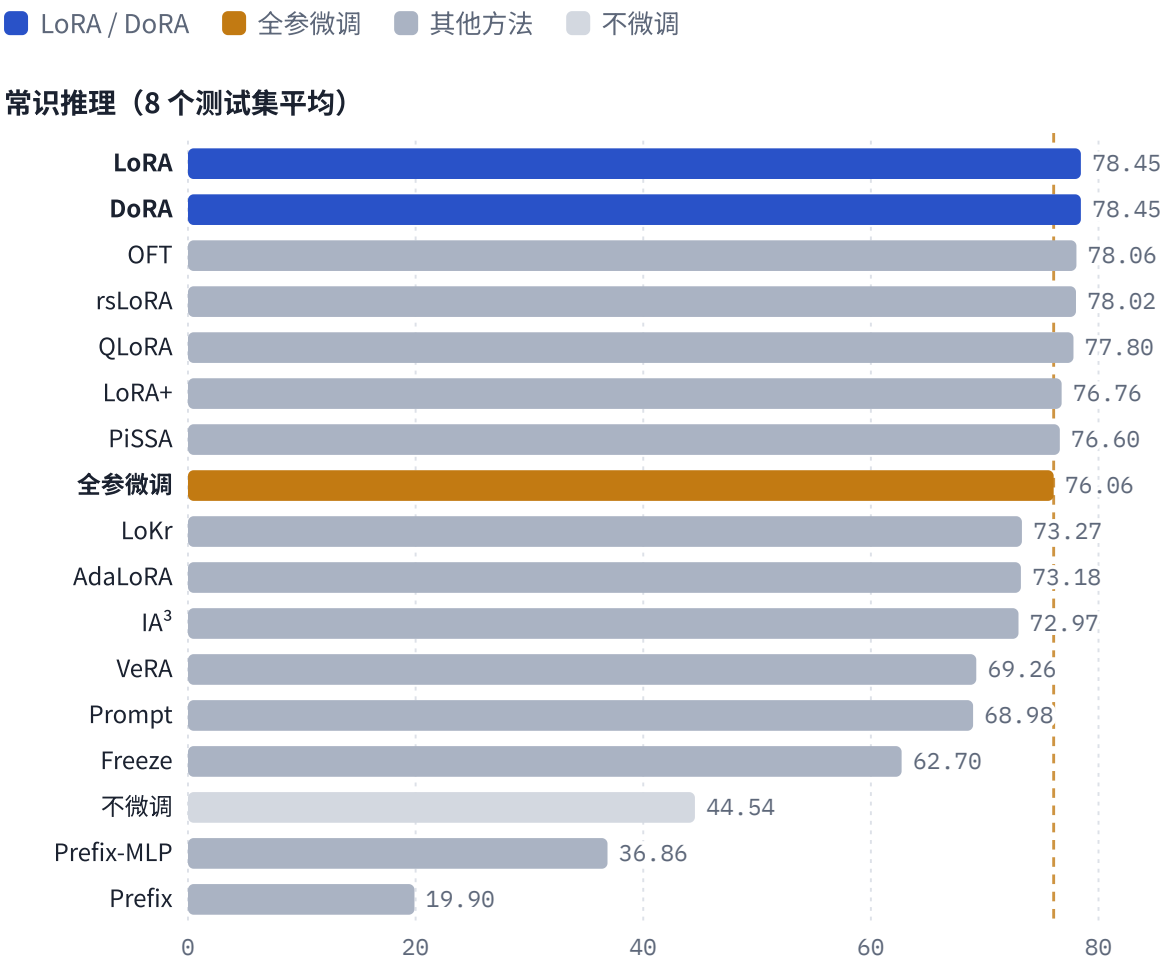
常识推理（8 个测试集平均）	数学推理 GSM8K	训练峰值显存	通用知识遗忘（MMLU 下降）
103%	102%	−49%	1/9
LoRA 78.45 vs 全参 76.06	LoRA 69.90 vs 全参 68.76	LoRA 8.65 GB vs 全参 16.9 GB	LoRA −0.91 分 vs 全参 −8.48 分

主要结论

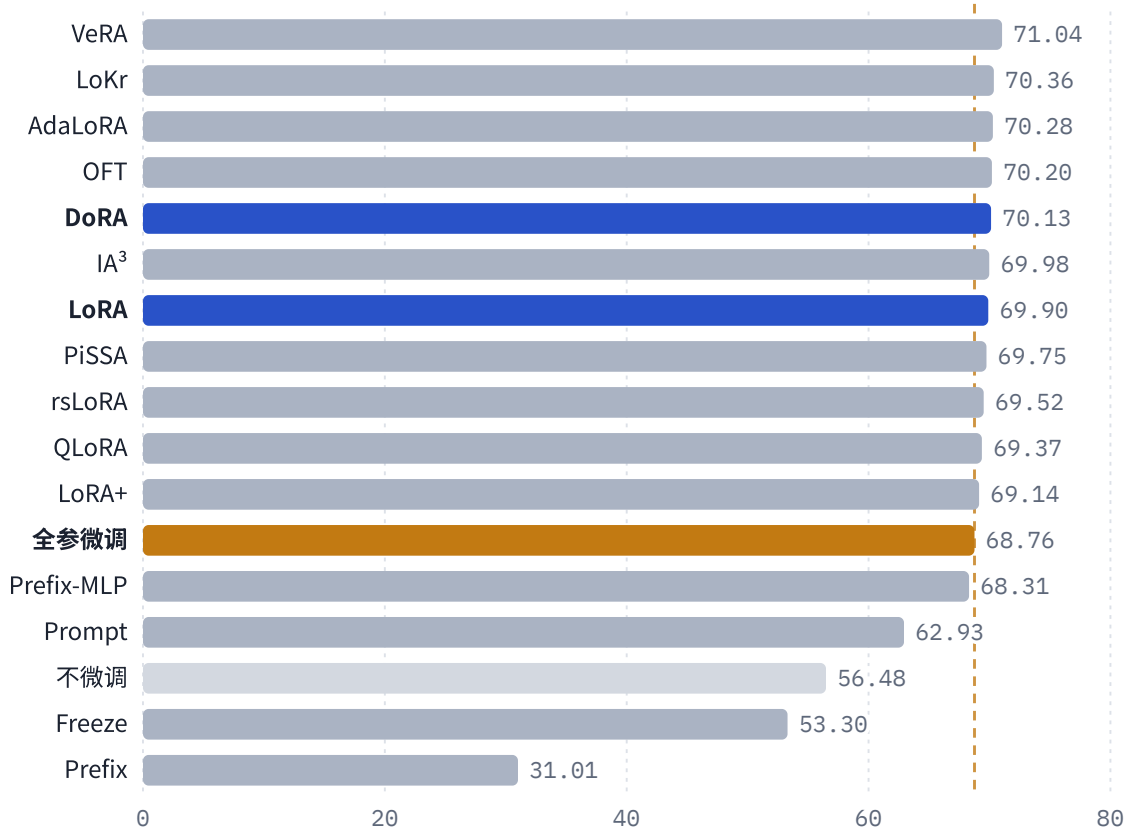
1. **LoRA 是综合最优的选择**：常识推理并列第一（78.45），GSM8K 69.90，显存 8.65 GB，训练 15 分钟，遗忘小。
2. **DoRA 分数与 LoRA 持平或略高**，MATH-500 37.8 更好，但训练时间是 LoRA 的 2.2 倍。
3. **全参微调遗忘最严重**：MMLU 掉 8.5 分；更新幅度越大的方法遗忘越重（LoRA+ 掉 7.4，rsLoRA 掉 3.9）。
4. **QLoRA 在 1.5B 模型上收益有限**：只省 0.7 GB 显存且慢 33%，难题（MATH-500）上比 LoRA 低 4 分；它的价值在 7B 以上模型。
5. **极少参数方法各有偏科**：VeRA 只训 0.045% 参数，GSM8K 最高（71.04），但常识推理掉约 9 分。
6. **Prefix-Tuning 在该设置下失效**：常识推理 19.9、MMLU 接近随机，已用三种解码方式排除评测错误。

各方法任务得分

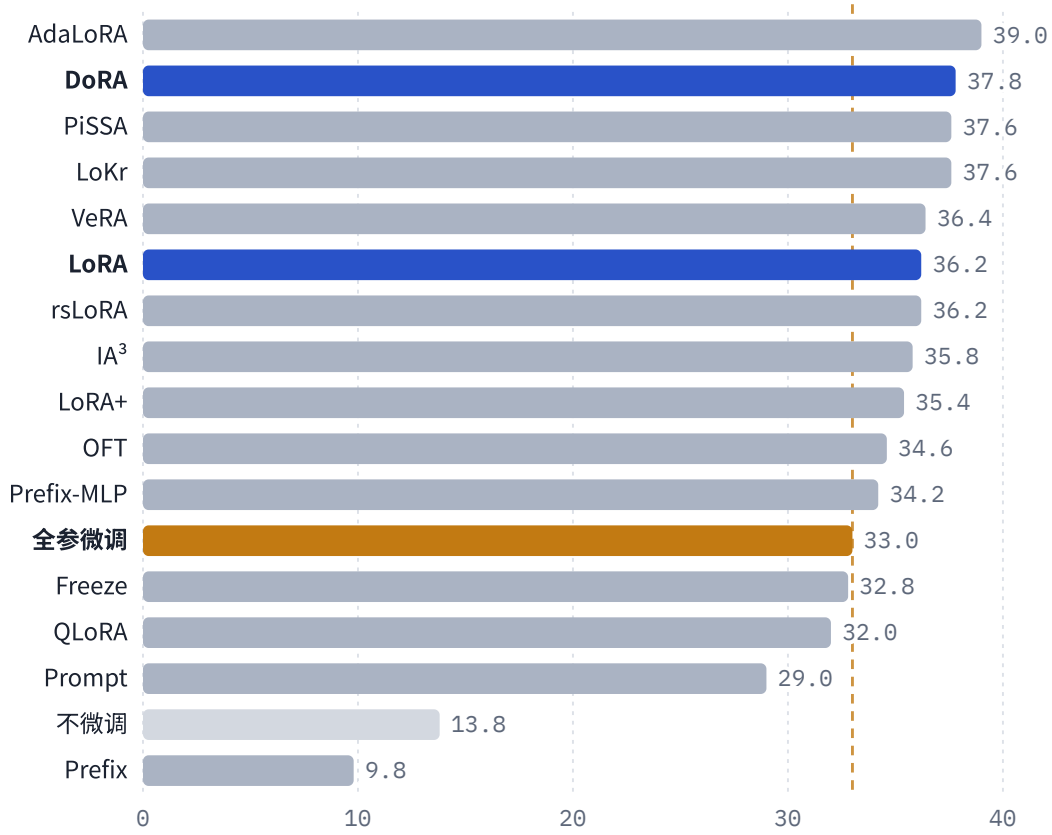
橙色虚线是全参微调的分数，越过虚线说明这种方法用更少的参数达到或超过了全参微调。



GSM8K 数学



MATH-500 难题



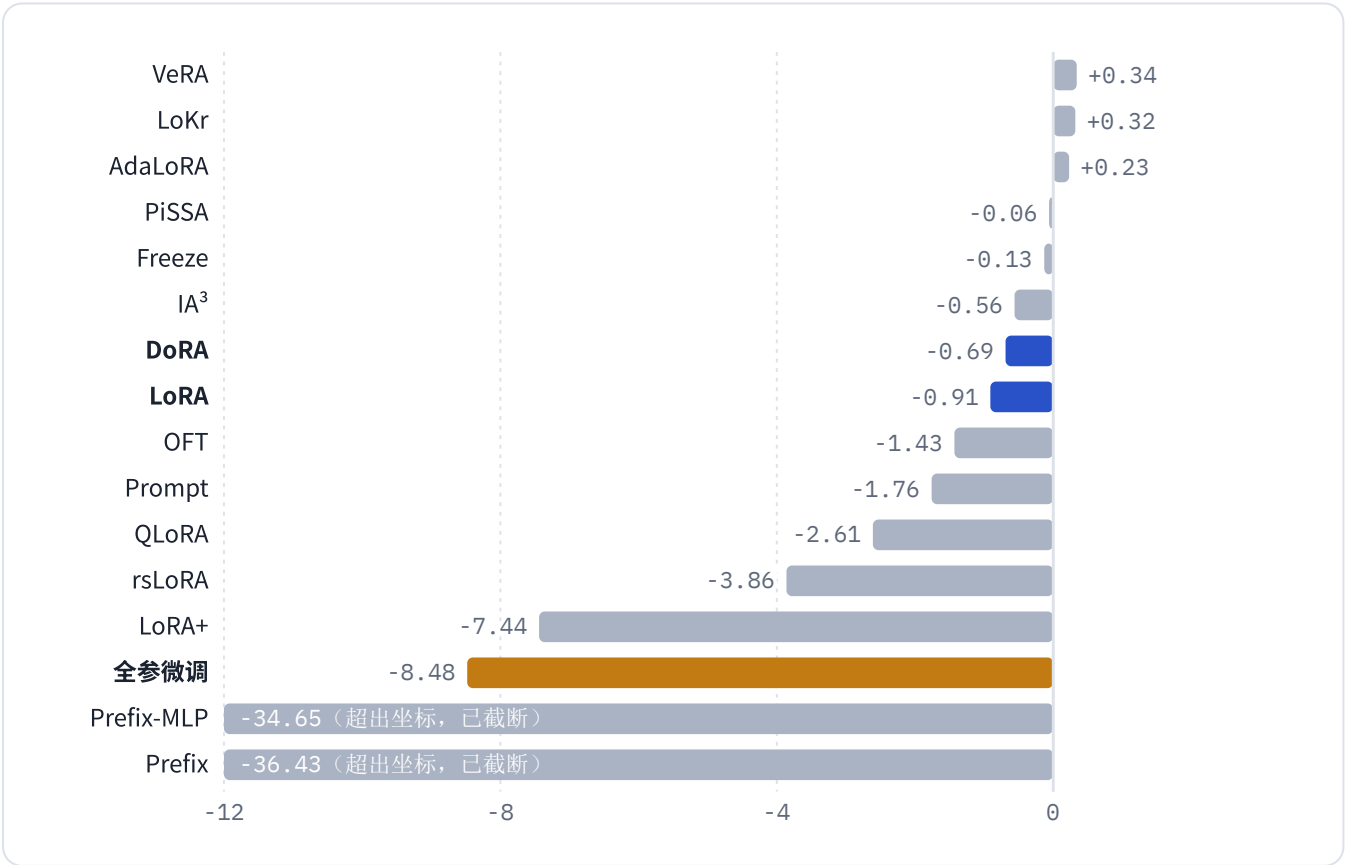
显存与效果：越靠左上越好

横轴是常识推理任务的训练峰值显存，纵轴是准确率。LoRA 家族聚在左上角；全参微调显存最高，效果反而略低。



微调后通用知识掉了多少（MMLU）

在常识推理数据上微调后，再测 MMLU（57 个学科、14,042 题）。基座 61.05 分，条形表示相对基座的变化，越短越好。



完整结果

方法	常识推理	GSM8K	MATH-500	MMLU 变化	可训练参数	显存 (GB)	训练时间 (min)
不微调	44.54	56.48	13.8	–	0	–	–
全参微调	76.06	68.76	33.0	-8.48	100%	16.9	26.5
Freeze	62.70	53.30	32.8	-0.13	6.06%	13	10
LoRA	78.45	69.90	36.2	-0.91	1.18%	8.65	15.4
QLoRA	77.80	69.37	32.0	-2.61	1.18%	7.96	20.5
DoRA	78.45	70.13	37.8	-0.69	1.22%	8.66	34.4
rsLoRA	78.02	69.52	36.2	-3.86	1.18%	8.65	15.6
PiSSA	76.60	69.75	37.6	-0.06	1.18%	8.65	14.6
LoRA+	76.76	69.14	35.4	-7.44	1.18%	8.65	15.4
AdaLoRA	73.18	70.28	39.0	+0.23	1.76%	9.2	23.2
VeRA	69.26	71.04	36.4	+0.34	0.045%	8.4	18.1
IA^3	72.97	69.98	35.8	-0.56	0.017%	8.38	10.8
OFT	78.06	70.20	34.6	-1.43	0.51%	8.49	21.3
LoKr	73.27	70.36	37.6	+0.32	0.043%	8.38	21.5
Prefix	19.90	31.01	9.8	-36.43	0.030%	14.5	6.9
Prefix-MLP	36.86	68.31	34.2	-34.65	0.48%	14.6	6.9
Prompt	68.98	62.93	29.0	-1.76	0.003%	15.5	7.3

准确率单位为 %。显存和训练时间为常识推理任务（2 万条、1 epoch）；MMLU 变化为常识微调后相对基座 61.05 的差值。

代码与原始结果：github.com/ShiinaHikariJ/peft-bench

苏州大学 · 颜晟帆 · 2026 年 11 月

实验设置

基座模型	Qwen2.5-1.5B	硬件	单卡 RTX 4090 24GB，总计约 13 小时
常识推理	Commonsense170K 抽 2 万条训练；8 个测试集共 22,419 题	数学推理	MetaMathQA 抽 2 万条训练；GSM8K 1,319 题、MATH-500
训练	1 epoch，有效 batch 32，cosine，各方法推荐学习率	框架	transformers 5.8 + PEFT 0.18.1，统一脚本一条命令切换方法

局限：每组单个随机种子，0.5 分以内的差距不宜下结论；只测了 1.5B 一个规模。下一步计划在 7B 模型和垂直领域数据上复测。